

Analyse des thèmes dans les romans de Zola

Morgan RICHARD

1 Introduction

Émile Zola, l'un des écrivains les plus célèbres du XIXe siècle, est connu pour ses romans naturalistes qui explorent les aspects sociaux, économiques et psychologiques de la vie humaine.

Dans cette analyse, nous allons examiner les thèmes récurrents dans les œuvres de Zola et savoir s'il y a bien des thèmes recurent dans plusieurs de ses romans. Des methode d'analyse textuelle seront utilisées pour identifier les thèmes principaux à travers les différents romans.

Ce travail est le premier d'une série d'analyses sur un corpus de textes littéraires issues de différents auteurs natuaralistes et non naturalistes.

Deux methode d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola :

- Le NMF (Non-negative Matrix Factorization)¹ : une technique de réduction de dimensionnalité qui permet d'extraire des thèmes à partir d'un corpus de textes.
- Kmeans : une méthode de clustering qui permet de regrouper les thèmes récurrents en fonction de leur similarité thématique.

Ces methodes seront expliquées en détail dans les sections suivantes, où nous présenterons les résultats de l'analyse thématique des romans de Zola.

2 Présentation du corpus

Comme dit en introduction, ce travail porte sur un corpus de textes de Zola. Un Choix a été fait de n'inclure que ces romans pour cette analyse, afin de se concentrer sur les thèmes récurrents dans l'œuvre de cet auteur. Aucune nouvelles n'a été utilisée pour cette analyse, car les romans de Zola sont plus longs et offrent une richesse thématique plus importante que les nouvelles, de

1. N. Gillis, *Nonnegative Matrix Factorization*, Society for Industrial and Applied Mathematics, coll. « Data Science », 2020.

plus il peut y avoir un déséquilibre entre ces deux types de textes, cela pourrait fausser les résultats de l'analyse thématique.

Le corpus comprend les romans suivants :

TABLE 1: Corpus des œuvres de Zola utilisées dans l'analyse

Date	Titre	Fichier
1865	La confession de Claude	1865_La_confession_de_Claude._clean.txt
1866	Le vœu d'une morte	1866_Le_voeu_d_une_morte._clean.txt
1867	Les mystères de Marseille	1867_Les_mysteres_de_Marseille._clean.txt
1867	Thérèse Raquin	1867_Therese_Raquin._clean.txt
1868	Madeleine Férat	1868_Madeleine_Ferat._clean.txt
1871	La fortune des Rougon	1871_1_La_fortune_des_Rougon._clean.txt
1872	La curée	1871_2_La_curee._clean.txt
1873	Le ventre de Paris	1873_3_Le_ventre_de_Paris._clean.txt
1874	La conquête de Plassans	1874_4_La_conquete_de_Plassans._clean.txt
1875	La faute de l'abbé Mouret	1875_5_La_faute_de_l_abbe_Mouret._clean.txt
1876	Son Excellence Eugène Rougon	1876_6_Son_Excurrence_Eugene_Rougon._clean.txt
1877	L'assommoir	1877_7_L_assommoir._clean.txt
1878	Une page d'amour	1878_8_Une_page_d_amour._clean.txt
1880	Nana	1880_9_Nana._clean.txt
1882	Pot-Bouille	1882_10_Pot-bouille._clean.txt
1883	Au Bonheur des dames	1883_11_Au_Bonheur_des_dames._clean.txt
1884	La joie de vivre	1884_12_La_joye_de_vivre._clean.txt
1885	Germinal	1885_13_Germinal._clean.txt
1886	L'œuvre	1886_14_L_oeuvre._clean.txt
1887	La terre	1887_15_La_terre._clean.txt
1888	Le rêve	1888_16_Le_reve._clean.txt
1890	La bête humaine	1890_17_La_bete_humaine._clean.txt
1891	L'argent	1891_18_L_argent._clean.txt
1892	La débâcle	1892_19_La_debacle._clean.txt
1893	Le docteur Pascal	1893_20_Le_docteur_Pascal._clean.txt
1894	Lourdes	1894_1_Lourdes._clean.txt
1896	Rome	1896_2_Rome._clean.txt
1898	Paris	1898_3_Paris._clean.txt
1899	Fécondité	1899_1_Fecondite._clean.txt
1901	Travail	1901_2_Travail._clean.txt
1903	Vérité	1903_3_Verite._clean.txt

Nous constatons que le corpus de romans est composé de 31 romans, il y a l'intégralité des romans de Zola :

- 5 : romans antérieurs
- 20 : Rougon-Macquart
- 3 : Trois Villes

Pour ce qui est des Quatres Évangiles, Vérité paraît à titre posthume. Et Justice ne paraîtra jamais, l'ouvrage étant resté à l'état d'ébauche au moment de la mort de l'écrivain.

3 Méthodologie de préparation des données

3.1 Préparation des données brutes en données propres

Les romans au format `.txt` correspondent à des versions nettoyées, c'est-à-dire à des textes dont les éléments non textuels ont été supprimés. Ces éléments comprennent notamment les titres, les chapitres, les notes de bas de page et d'autres informations éditoriales qui pourraient perturber l'analyse. Ce nettoyage permet d'obtenir une représentation plus précise des thèmes présents dans les romans.

De plus, le choix a été fait de conserver une seule phrase par ligne. Ce format facilite l'analyse textuelle, notamment pour les méthodes de NMF et de K-means, qui nécessitent une structure de données homogène pour fonctionner correctement.

Cette logique de formatage a également été appliquée en prévision des analyses futures. Les romans issus de prochains traitements pourront ainsi être intégrés de manière cohérente au corpus. Ce choix permet de limiter les différences de structure entre les fichiers et d'obtenir un format homogène pour l'analyse sans trop complexifier le processus de préparation des données.

3.2 Préparation du corpus pour l'analyse thématique

Pour effectuer l'analyse sur le corpus des romans de Zola, j'ai procédé de la façon qui m'a semblé la plus pertinente pour obtenir des résultats fiables et significatifs.

J'ai segmenté les romans en paquets de phrases. Les paquets étaient composés de 40 phrases, ce qui correspond à une taille de texte suffisante pour capturer les thèmes présents dans les romans, tout en permettant une analyse thématique plus fine. Bien entendu, ce choix de taille de paquet est arbitraire et pourrait être ajusté en fonction des besoins de l'analyse. Plusieurs tailles de paquets ont été testées² et des paquets 40 phrases ont été retenues car elles permettent d'obtenir des résultats plus cohérents et significatifs que les autres tailles testées. Ce choix relève d'un arbitrage méthodologique fondé sur des essais empirique et une analyse qualitative des résultats obtenus avec différentes tailles de paquets.

Le code suivant permet de segmenter les romans en paquets de 40 phrases.

Listing 1 – Code de segmentation du texte en paquets de phrases

2. J'ai procédé à différents tests, des paquets de 10 phrases, 50, 70 et 100

```

1 def segmenter_en_paquets(texte, taille_paquet=40):
2     # Segmente le texte en paquets de phrases
3     phrases = texte.splitlines()
4     phrases = [p.strip() for p in phrases if p.strip()]
5     paquets = []
6
7     for i in range(0, len(phrases), taille_paquet):
8         paquet = "␣".join(phrases[i:i+taille_paquet])
9         paquets.append(paquet)
10    return paquets
11
12    rows = []
13
14    for _, row in df.iterrows():
15        # Iteration sur chaque ligne du DataFrame
16        paquets = segmenter_en_paquets(row["texte_brut"])
17
18        for idx, paquet in enumerate(paquets):
19            rows.append({
20                "nom_fichier": row["nom_fichier"],
21                "id_paquet": idx,
22                "phrases_paquet": paquet
23            })
24
25    df_phrases = pd.DataFrame(rows)

```

Listing 1 – Code de segmentation du texte en paquets de phrases

3.3 Statistiques descriptives du corpus

3.4 Lemmatisation du corpus de Zola