

# Analyse des thèmes dans les romans de Zola

Morgan RICHARD

## 1 Introduction

Émile Zola, l'un des écrivains les plus célèbres du XIX<sup>e</sup> siècle, est connu pour ses romans naturalistes qui explorent les aspects sociaux, économiques et psychologiques de la vie humaine.

Dans cette analyse, nous allons examiner les thèmes récurrents dans les œuvres de Zola et savoir s'il y a bien des thèmes recurent dans plusieurs de ses romans. Des methode d'analyse textuelle seront utilisées pour identifier les thèmes principaux à travers les différents romans.

Ce travail est le premier d'une série d'analyses sur un corpus de textes littéraires issues de différents auteurs natuaralistes et non naturalistes.

Deux methode d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola :

- Le NMF (Non-negative Matrix Factorization)<sup>1</sup> : une technique de réduction de dimensionnalité qui permet d'extraire des thèmes à partir d'un corpus de textes.
- Kmeans : une méthode de clustering qui permet de regrouper les thèmes récurrents en fonction de leur similarité thématique.

Ces methodes seront expliquées en détail dans les sections suivantes, où nous présenterons les résultats de l'analyse thématique des romans de Zola.

## 2 Présentation du corpus

Comme dit en introduction, ce travail porte sur un corpus de textes de Zola. Un Choix a été fait de n'inclure que ces romans pour cette analyse, afin de se concentrer sur les thèmes récurrents dans l'œuvre de cet auteur. Aucune nouvelles n'a été utilisée pour cette analyse, car les romans de Zola sont plus longs et offrent une richesse thématique plus importante que les nouvelles, de

---

1. N. Gillis, *Nonnegative Matrix Factorization*, Society for Industrial and Applied Mathematics, coll. « Data Science », 2020.

plus il peut y avoir un déséquilibre entre ces deux types de textes, cela pourrait fausser les résultats de l'analyse thématique.

Le corpus comprend les romans suivants :

TABLE 1: Corpus des œuvres de Zola utilisées dans l'analyse

| Date | Titre                        | Fichier                                        |
|------|------------------------------|------------------------------------------------|
| 1865 | La confession de Claude      | 1865_La_confession_de_Claude._clean.txt        |
| 1866 | Le vœu d'une morte           | 1866_Le_voeu_d_une_morte._clean.txt            |
| 1867 | Les mystères de Marseille    | 1867_Les_mysteres_de_Marseille._clean.txt      |
| 1867 | Thérèse Raquin               | 1867_Therese_Raquin._clean.txt                 |
| 1868 | Madeleine Férat              | 1868_Madeleine_Ferat._clean.txt                |
| 1871 | La fortune des Rougon        | 1871_1_La_fortune_des_Rougon._clean.txt        |
| 1872 | La curée                     | 1871_2_La_curee._clean.txt                     |
| 1873 | Le ventre de Paris           | 1873_3_Le_ventre_de_Paris._clean.txt           |
| 1874 | La conquête de Plassans      | 1874_4_La_conquete_de_Plassans._clean.txt      |
| 1875 | La faute de l'abbé Mouret    | 1875_5_La_faute_de_l_abbe_Mouret._clean.txt    |
| 1876 | Son Excellence Eugène Rougon | 1876_6_Son_Excellence_Eugene_Rougon._clean.txt |
| 1877 | L'assommoir                  | 1877_7_L_assommoir._clean.txt                  |
| 1878 | Une page d'amour             | 1878_8_Une_page_d_amour._clean.txt             |
| 1880 | Nana                         | 1880_9_Nana._clean.txt                         |
| 1882 | Pot-Bouille                  | 1882_10_Pot-bouille._clean.txt                 |
| 1883 | Au Bonheur des dames         | 1883_11_Au_Bonheur_des_dames._clean.txt        |
| 1884 | La joie de vivre             | 1884_12_La_joye_de_vivre._clean.txt            |
| 1885 | Germinal                     | 1885_13_Germinal._clean.txt                    |
| 1886 | L'œuvre                      | 1886_14_L_oeuvre._clean.txt                    |
| 1887 | La terre                     | 1887_15_La_terre._clean.txt                    |
| 1888 | Le rêve                      | 1888_16_Le_reve._clean.txt                     |
| 1890 | La bête humaine              | 1890_17_La_bete_humaine._clean.txt             |
| 1891 | L'argent                     | 1891_18_L_argent._clean.txt                    |
| 1892 | La débâcle                   | 1892_19_La_debacle._clean.txt                  |
| 1893 | Le docteur Pascal            | 1893_20_Le_docteur_Pascal._clean.txt           |
| 1894 | Lourdes                      | 1894_1_Lourdes._clean.txt                      |
| 1896 | Rome                         | 1896_2_Rome._clean.txt                         |
| 1898 | Paris                        | 1898_3_Paris._clean.txt                        |
| 1899 | Fécondité                    | 1899_1_Fecondite._clean.txt                    |
| 1901 | Travail                      | 1901_2_Travail._clean.txt                      |
| 1903 | Vérité                       | 1903_3_Verite._clean.txt                       |

Nous constatons que le corpus de romans est composé de 31 romans, il y a l'intégralité des romans de Zola :

- 5 : romans antérieurs
- 20 : Rougon-Macquart

- 3 : Trois Villes
- 3 : Quatre Évangiles publiés

Pour ce qui est des Quatres Évangiles, Vérité paraît à titre posthume. Et Justice ne paraîtra jamais, l’ouvrage étant resté à l’état d’ébauche au moment de la mort de l’écrivain.

### 3 Méthodologie de préparation des données

#### 3.1 Préparation des données brutes en données propres

Les romans au format `.txt` correspondent à des versions nettoyées, c’est-à-dire à des textes dont les éléments non textuels ont été supprimés. Ces éléments comprennent notamment les titres, les chapitres, les notes de bas de page et d’autres informations éditoriales qui pourraient perturber l’analyse. Ce nettoyage permet d’obtenir une représentation plus précise des thèmes présents dans les romans.

De plus, le choix a été fait de conserver une seule phrase par ligne. Ce format facilite l’analyse textuelle, notamment pour les méthodes de NMF et de K-means, qui nécessitent une structure de données homogène pour fonctionner correctement.

Cette logique de formatage a également été appliquée en prévision des analyses futures. Les romans issus de prochains traitements pourront ainsi être intégrés de manière cohérente au corpus. Ce choix permet de limiter les différences de structure entre les fichiers et d’obtenir un format homogène pour l’analyse sans trop complexifier le processus de préparation des données.

TABLE 2: Nombre de tokens par roman dans l’ordre chronologique

| Titre du roman               | Nombre de tokens |
|------------------------------|------------------|
| La confession de Claude      | 47253            |
| Le vœu d’une morte           | 38722            |
| Les mystères de Marseille    | 125253           |
| Thérèse Raquin               | 66363            |
| Madeleine Féral              | 97318            |
| La fortune des Rougon        | 116685           |
| La curée                     | 105120           |
| Le ventre de Paris           | 110442           |
| La conquête de Plassans      | 113245           |
| La faute de l’abbé Mouret    | 114667           |
| Son Excellence Eugène Rougon | 126186           |
| L’assommoir                  | 158340           |
| Une page d’amour             | 102185           |
| Nana                         | 141573           |
| Pot-Bouille                  | 134844           |

| Titre du roman       | Nombre de tokens |
|----------------------|------------------|
| Au Bonheur des dames | 147521           |
| La joie de vivre     | 117255           |
| Germinal             | 164473           |
| L'œuvre              | 130613           |
| La terre             | 163687           |
| Le rêve              | 66379            |
| La bête humaine      | 125418           |
| L'argent             | 143010           |
| La débâcle           | 187046           |
| Le docteur Pascal    | 112713           |
| Lourdes              | 173511           |
| Rome                 | 233958           |
| Paris                | 177389           |
| Fécondité            | 220131           |
| Travail              | 198712           |
| Vérité               | 223274           |

Le tableau fournit une description quantitative du corpus en indiquant, pour chaque roman, le nombre de tokens obtenus après nettoyage. Les œuvres sont présentées dans l'ordre chronologique, ce qui permet d'observer l'évolution du volume textuel au sein de la production romanesque de Zola. Les écarts sont importants entre les romans courts du début de carrière, comme *Le vœu d'une morte*, et les œuvres plus volumineuses de la fin de carrière, notamment *Rome*, *Fécondité*, *Travail* et *Vérité*.

Cette information est importante pour l'interprétation des résultats, car la longueur des textes peut avoir un effet sur la représentation des thèmes. Un roman plus long fournit mécaniquement davantage d'occurrences lexicales et davantage de segments analysables. La segmentation en paquets de phrases vise donc à produire des unités d'analyse plus comparables, tout en conservant suffisamment de contexte pour identifier les thèmes dominants.

### 3.2 Préparation du corpus pour l'analyse thématique

Pour effectuer l'analyse sur le corpus des romans de Zola, j'ai procédé de la façon qui m'a semblé la plus pertinente pour obtenir des résultats fiables et significatifs.

J'ai segmenté les romans en paquets de phrases. Les paquets étaient composés de 40 phrases, ce qui correspond à une taille de texte suffisante pour capturer les thèmes présents dans les romans, tout en permettant une analyse thématique plus fine. Bien entendu, ce choix de taille de paquet est arbitraire et pourrait être ajusté en fonction des besoins de l'analyse. Plusieurs tailles de paquets ont été testées<sup>2</sup> et des paquets 40 phrases ont été retenues car elles permettent

2. J'ai procédé à différents tests, des paquets de 10 phrases, 50, 70 et 100

d'obtenir des résultats plus cohérents et significatifs que les autres tailles testées. Ce choix relève d'un arbitrage méthodologique fondé sur des essais empirique et une analyse qualitative des résultats obtenus avec différentes tailles de paquets.

Le code suivant permet de segmenter les romans en paquets de 40 phrases.

```

1 def segmenter_en_paquets(texte, taille_paquet=40):
2     # Segmente le texte en paquets de phrases
3     phrases = texte.splitlines()
4     phrases = [p.strip() for p in phrases if p.strip()]
5     paquets = []
6
7     for i in range(0, len(phrases), taille_paquet):
8         paquet = " ".join(phrases[i:i+taille_paquet])
9         paquets.append(paquet)
10    return paquets
11
12 rows = []
13
14 for _, row in df.iterrows():
15     # Iteration sur chaque ligne du DataFrame
16     paquets = segmenter_en_paquets(row["texte_brut"])
17
18     for idx, paquet in enumerate(paquets):
19         rows.append({
20             "nom_fichier": row["nom_fichier"],
21             "id_paquet": idx,
22             "phrases_paquet": paquet
23         })
24
25 df_phrases = pd.DataFrame(rows)

```

Listing 1 – Code de segmentation du texte en paquets de phrases

### 3.3 Statistiques descriptives du corpus

TABLE 3: Nombre de paquets de phrases par roman

| Titre du roman            | Nombre de paquets |
|---------------------------|-------------------|
| La confession de Claude   | 65                |
| Le vœu d'une morte        | 60                |
| Les mystères de Marseille | 184               |
| Thérèse Raquin            | 80                |
| Madeleine Féral           | 124               |
| La fortune des Rougon     | 154               |
| La curée                  | 123               |

| Titre du roman               | Nombre de paquets |
|------------------------------|-------------------|
| Le ventre de Paris           | 136               |
| La conquête de Plassans      | 165               |
| La faute de l'abbé Mouret    | 171               |
| Son Excellence Eugène Rougon | 191               |
| L'assommoir                  | 228               |
| Une page d'amour             | 166               |
| Nana                         | 225               |
| Pot-Bouille                  | 207               |
| Au Bonheur des dames         | 198               |
| La joie de vivre             | 164               |
| Germinal                     | 225               |
| L'œuvre                      | 163               |
| La terre                     | 222               |
| Le rêve                      | 82                |
| La bête humaine              | 154               |
| L'argent                     | 155               |
| La débâcle                   | 221               |
| Le docteur Pascal            | 135               |
| Lourdes                      | 198               |
| Rome                         | 231               |
| Paris                        | 206               |
| Fécondité                    | 259               |
| Travail                      | 208               |
| Vérité                       | 227               |

Ce tableau indique le nombre de paquets de phrases obtenus pour chaque roman après segmentation du corpus. Les écarts observés reflètent principalement les différences de longueur entre les œuvres : les textes les plus courts, comme *Le vœu d'une morte* ou *La confession de Claude*, produisent peu de paquets, tandis que les romans plus volumineux, comme *Fécondité*, *Rome* ou *L'assommoir*, en produisent davantage.

TABLE 4 – Statistiques descriptives du nombre de paquets par roman

| Indicateur         | Valeur |
|--------------------|--------|
| Nombre de romans   | 31     |
| Moyenne            | 171.84 |
| Écart-type         | 52.40  |
| Minimum            | 60     |
| Premier quartile   | 145    |
| Médiane            | 171    |
| Troisième quartile | 214.5  |
| Maximum            | 259    |

Le corpus contient en moyenne environ 172 paquets de phrases par roman, avec une médiane très proche de cette valeur, située à 171 paquets. Cette proximité entre moyenne et médiane indique que la distribution n'est pas fortement déséquilibrée, même si les romans présentent des longueurs variables.

L'écart-type est d'environ 52 paquets, ce qui montre une dispersion notable autour de la moyenne. Cette variation reste cependant cohérente avec la nature du corpus, puisque certains romans courts ne produisent qu'une soixantaine de paquets, tandis que les textes les plus longs peuvent en produire jusqu'à 259.

Le coefficient de variation est d'environ 30 % puisqu'il correspond au rapport entre l'écart-type et la moyenne. Cela indique une variabilité modérée du nombre de paquets entre les œuvres, qu'il faudra garder à l'esprit lors de l'interprétation des résultats thématiques.

### **3.4 Lemmatisation du corpus de Zola**