

Analyse des thèmes dans les romans de Zola

Morgan RICHARD

1 Introduction

Émile Zola, l'un des écrivains les plus célèbres du XIXe siècle, est connu pour ses romans naturalistes qui explorent les aspects sociaux, économiques et psychologiques de la vie humaine.

Dans cette analyse, nous allons examiner les thèmes récurrents dans les œuvres de Zola et déterminer s'ils apparaissent dans plusieurs de ses romans. Des méthodes d'analyse textuelle seront utilisées pour identifier les thèmes principaux à travers les différents romans.

Ce travail est le premier d'une série d'analyses portant sur un corpus de textes littéraires issus de différents auteurs naturalistes et non naturalistes.

Deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola :

- Le NMF (Non-negative Matrix Factorization)¹ : une technique de réduction de dimensionnalité qui permet d'extraire des thèmes à partir d'un corpus de textes.
- K-means : une méthode de clustering qui permet de regrouper les thèmes récurrents en fonction de leur similarité thématique.

Ces méthodes seront expliquées en détail dans les sections suivantes, où nous présenterons les résultats de l'analyse thématique des romans de Zola.

1. N. Gillis, *Nonnegative Matrix Factorization*, Society for Industrial and Applied Mathematics, coll. « Data Science », 2020.

2 Présentation du corpus

Comme indiqué en introduction, ce travail porte sur un corpus de textes de Zola. Le choix a été fait de n'inclure que ses romans dans cette analyse, afin de se concentrer sur les thèmes récurrents dans l'œuvre de cet auteur. Aucune nouvelle n'a été utilisée pour cette analyse, car les romans de Zola sont plus longs et offrent une richesse thématique plus importante que les nouvelles. De plus, un déséquilibre entre ces deux types de textes pourrait fausser les résultats de l'analyse thématique.

Le corpus comprend les romans suivants :

TABLE 1: Corpus des œuvres de Zola utilisées dans l'analyse

Date	Titre	Fichier
1865	La confession de Claude	1865_La_confession_de_Claude._clean.txt
1866	Le vœu d'une morte	1866_Le_voeu_d_une_morte._clean.txt
1867	Les mystères de Marseille	1867_Les_mysteres_de_Marseille._clean.txt
1867	Thérèse Raquin	1867_Therese_Raquin._clean.txt
1868	Madeleine Férat	1868_Madeleine_Ferat._clean.txt
1871	La fortune des Rougon	1871_1_La_fortune_des_Rougon._clean.txt
1872	La curée	1871_2_La_curee._clean.txt
1873	Le ventre de Paris	1873_3_Le_ventre_de_Paris._clean.txt
1874	La conquête de Plassans	1874_4_La_conquete_de_Plassans._clean.txt
1875	La faute de l'abbé Mouret	1875_5_La_faute_de_l_abbe_Mouret._clean.txt
1876	Son Excellence Eugène Rougon	1876_6_Son_Excellence_Eugene_Rougon._clean.txt
1877	L'assommoir	1877_7_L_assommoir._clean.txt
1878	Une page d'amour	1878_8_Une_page_d_amour._clean.txt
1880	Nana	1880_9_Nana._clean.txt
1882	Pot-Bouille	1882_10_Pot-bouille._clean.txt
1883	Au Bonheur des dames	1883_11_Au_Bonheur_des_dames._clean.txt
1884	La joie de vivre	1884_12_La_joye_de_vivre._clean.txt
1885	Germinal	1885_13_Germinal._clean.txt
1886	L'œuvre	1886_14_L_oeuvre._clean.txt
1887	La terre	1887_15_La_terre._clean.txt
1888	Le rêve	1888_16_Le_reve._clean.txt
1890	La bête humaine	1890_17_La_bete_humaine._clean.txt
1891	L'argent	1891_18_L_argent._clean.txt
1892	La débâcle	1892_19_La_debacle._clean.txt
1893	Le docteur Pascal	1893_20_Le_docteur_Pascal._clean.txt
1894	Lourdes	1894_1_Lourdes._clean.txt
1896	Rome	1896_2_Rome._clean.txt
1898	Paris	1898_3_Paris._clean.txt
1899	Fécondité	1899_1_Fecondite._clean.txt
1901	Travail	1901_2_Travail._clean.txt

Date	Titre	Fichier
1903	Vérité	1903_3_Verite._clean.txt

Nous constatons que le corpus est composé de 31 romans, correspondant aux principaux romans publiés de Zola :

- 5 : romans antérieurs aux *Rougon-Macquart*
- 20 : Rougon-Macquart
- 3 : Trois Villes
- 3 : Quatre Évangiles publiés

Pour ce qui est des *Quatre Évangiles*, *Vérité* paraît à titre posthume. *Justice* ne paraîtra jamais, l'ouvrage étant resté à l'état d'ébauche au moment de la mort de l'écrivain.

3 Méthodologie de préparation des données

3.1 Préparation des données brutes en données propres

Les romans au format `.txt` correspondent à des versions nettoyées, c'est-à-dire à des textes dont les éléments non textuels ont été supprimés. Ces éléments comprennent notamment les titres, les chapitres, les notes de bas de page et d'autres informations éditoriales qui pourraient perturber l'analyse. Ce nettoyage permet d'obtenir une représentation plus précise des thèmes présents dans les romans.

De plus, le choix a été fait de conserver une seule phrase par ligne. Ce format facilite l'analyse textuelle, notamment pour les méthodes de NMF et de K-means, qui nécessitent une structure de données homogène pour fonctionner correctement.

Cette logique de formatage a également été appliquée en prévision des analyses futures. Les romans issus de prochains traitements pourront ainsi être intégrés de manière cohérente au corpus. Ce choix permet de limiter les différences de structure entre les fichiers et d'obtenir un format homogène pour l'analyse sans trop complexifier le processus de préparation des données.

TABLE 2: Nombre de tokens par roman dans l'ordre chronologique

Titre du roman	Nombre de tokens
La confession de Claude	47253
Le vœu d'une morte	38722
Les mystères de Marseille	125253
Thérèse Raquin	66363
Madeleine Férat	97318
La fortune des Rougon	116685
La curée	105120
Le ventre de Paris	110442
La conquête de Plassans	113245
La faute de l'abbé Mouret	114667
Son Excellence Eugène Rougon	126186
L'assommoir	158340
Une page d'amour	102185
Nana	141573
Pot-Bouille	134844
Au Bonheur des dames	147521
La joie de vivre	117255
Germinal	164473
L'œuvre	130613
La terre	163687
Le rêve	66379
La bête humaine	125418
L'argent	143010

Titre du roman	Nombre de tokens
La débâcle	187046
Le docteur Pascal	112713
Lourdes	173511
Rome	233958
Paris	177389
Fécondité	220131
Travail	198712
Vérité	223274

Le tableau fournit une description quantitative du corpus en indiquant, pour chaque roman, le nombre de tokens obtenus après nettoyage. Les œuvres sont présentées dans l'ordre chronologique, ce qui permet d'observer l'évolution du volume textuel au sein de la production romanesque de Zola. Les écarts sont importants entre les romans courts du début de carrière, comme *Le vœu d'une morte*, et les œuvres plus volumineuses de la fin de carrière, notamment *Rome*, *Fécondité*, *Travail* et *Vérité*.

Cette information est importante pour l'interprétation des résultats, car la longueur des textes peut avoir un effet sur la représentation des thèmes. Un roman plus long fournit mécaniquement davantage d'occurrences lexicales et davantage de segments analysables. La segmentation en paquets de phrases vise donc à produire des unités d'analyse plus comparables, tout en conservant suffisamment de contexte pour identifier les thèmes dominants.

3.2 Préparation du corpus pour l'analyse thématique

Pour effectuer l'analyse sur le corpus des romans de Zola, nous avons procédé de la façon qui semblait la plus pertinente pour obtenir des résultats fiables et significatifs.

Les romans ont été segmentés en paquets de phrases. Les paquets étaient composés de 40 phrases, ce qui correspond à une taille de texte suffisante pour capturer les thèmes présents dans les romans, tout en permettant une analyse thématique plus fine. Bien entendu, ce choix de taille de paquet est arbitraire et pourrait être ajusté en fonction des besoins de l'analyse. Plusieurs tailles de paquets ont été testées² et les paquets de 40 phrases ont été retenus, car ils permettent d'obtenir des résultats plus cohérents et significatifs que les autres tailles testées. Ce choix relève d'un arbitrage méthodologique fondé sur des essais empiriques et sur une analyse qualitative des résultats obtenus avec différentes tailles de paquets.

Le code suivant permet de segmenter les romans en paquets de 40 phrases.

```

1 def segmenter_en_paquets(texte, taille_paquet=40):
2     # Segmente le texte en paquets de phrases

```

2. Différents essais ont été réalisés avec des paquets de 10, 50, 70 et 100 phrases.

```

3     phrases = texte.splitlines()
4     phrases = [p.strip() for p in phrases if p.strip()]
5     paquets = []
6
7     for i in range(0, len(phrases), taille_paquet):
8         paquet = " ".join(phrases[i:i+taille_paquet])
9         paquets.append(paquet)
10    return paquets
11
12    rows = []
13
14    for _, row in df.iterrows():
15        # Iteration sur chaque ligne du DataFrame
16        paquets = segmenter_en_paquets(row["texte_brut"])
17
18        for idx, paquet in enumerate(paquets):
19            rows.append({
20                "nom_fichier": row["nom_fichier"],
21                "id_paquet": idx,
22                "phrases_paquet": paquet
23            })
24
25    df_phrases = pd.DataFrame(rows)

```

Listing 1 – Code de segmentation du texte en paquets de phrases

3.3 Statistiques descriptives du corpus

TABLE 3: Nombre de paquets de phrases par roman

Titre du roman	Nombre de paquets
La confession de Claude	65
Le vœu d'une morte	60
Les mystères de Marseille	184
Thérèse Raquin	80
Madeleine Férat	124
La fortune des Rougon	154
La curée	123
Le ventre de Paris	136
La conquête de Plassans	165
La faute de l'abbé Mouret	171
Son Excellence Eugène Rougon	191
L'assommoir	228
Une page d'amour	166
Nana	225
Pot-Bouille	207
Au Bonheur des dames	198
La joie de vivre	164
Germinal	225

Titre du roman	Nombre de paquets
L'œuvre	163
La terre	222
Le rêve	82
La bête humaine	154
L'argent	155
La débâcle	221
Le docteur Pascal	135
Lourdes	198
Rome	231
Paris	206
Fécondité	259
Travail	208
Vérité	227

Ce tableau indique le nombre de paquets de phrases obtenus pour chaque roman après segmentation du corpus. Les écarts observés reflètent principalement les différences de longueur entre les œuvres : les textes les plus courts, comme *Le vœu d'une morte* ou *La confession de Claude*, produisent peu de paquets, tandis que les romans plus volumineux, comme *Fécondité*, *Rome* ou *L'assommoir*, en produisent davantage.

3.3.1 Analyse des statistiques descriptives du nombre de paquets par roman

TABLE 4 – Statistiques descriptives du nombre de paquets par roman

Indicateur	Valeur
Nombre de romans	31
Moyenne	171.84
Écart-type	52.40
Minimum	60
Premier quartile	145
Médiane	171
Troisième quartile	214.5
Maximum	259

Les statistiques descriptives du nombre de paquets par roman permettent d'évaluer la structure quantitative du corpus après segmentation. Le corpus comprend 31 romans, avec une moyenne d'environ 172 paquets de phrases par œuvre. La médiane, située à 171 paquets, est très proche de cette moyenne. Cette proximité indique que la distribution générale du nombre de paquets n'est pas fortement asymétrique : la majorité des romans se situe autour d'un volume intermédiaire, même si certains textes s'écartent nettement de cette tendance.

L'écart-type, d'environ 52 paquets, montre toutefois une dispersion importante autour de la moyenne. Cette variation s'explique principalement par les différences de longueur entre les romans. Les œuvres les plus courtes, comme *Le vœu d'une morte*, produisent seulement 60 paquets, tandis que les textes les plus longs, comme *Fécondité*, atteignent 259 paquets. L'écart entre le minimum et le maximum est donc notable, puisqu'il existe presque un rapport de un à quatre entre le roman le moins segmenté et le roman le plus segmenté.

Les quartiles permettent de préciser cette répartition. Le premier quartile, situé à 145 paquets, indique qu'un quart des romans contient 145 paquets ou moins. Le troisième quartile, situé à 214,5 paquets, indique qu'environ trois quarts des romans restent sous ce seuil. La moitié centrale du corpus se situe donc entre 145 et 214,5 paquets, ce qui montre que la majorité des œuvres conserve une taille relativement comparable après segmentation. Les valeurs extrêmes ne remettent donc pas en cause l'homogénéité générale du corpus, mais elles doivent être prises en compte dans l'interprétation des résultats.

Le coefficient de variation est d'environ 30 %, puisqu'il correspond au rapport entre l'écart-type et la moyenne. Cette valeur signale une variabilité modérée : les romans ne sont pas tous de taille équivalente, mais les écarts restent attendus pour un corpus littéraire composé d'œuvres publiées à des périodes différentes et appartenant à plusieurs cycles romanesques. Cette dispersion est donc méthodologiquement acceptable, à condition de garder à l'esprit que les romans les plus longs fournissent davantage d'unités d'analyse.

Cette information est importante pour l'analyse thématique. Chaque paquet de phrases constitue une unité soumise aux méthodes de topic modeling. Par conséquent, un roman plus long contribue mécaniquement à un plus grand nombre d'observations qu'un roman court. Les thèmes présents dans les romans volumineux peuvent donc être davantage représentés dans les résultats globaux. La segmentation en paquets de 40 phrases permet néanmoins de réduire cet effet, car elle transforme les romans en unités textuelles comparables, tout en conservant suffisamment de contexte pour identifier des thèmes cohérents.

Ainsi, ces statistiques montrent que le corpus présente un équilibre satisfaisant pour une analyse thématique. Les différences de taille entre les romans existent, mais elles sont documentées et peuvent être intégrées à l'interprétation des résultats. Cette étape descriptive permet donc de mieux contrôler les effets liés à la longueur des œuvres avant l'application des méthodes de NMF et de K-means.

3.3.2 Analyse des statistiques descriptives du nombre de mots par paquet

TABLE 5 – Statistiques descriptives du nombre de mots par paquet

Indicateur	Valeur
Nombre de paquets	5327
Moyenne	785.30
Écart-type	212.13
Minimum	42
Premier quartile	636
Médiane	753
Troisième quartile	902.5
Maximum	2944

Les statistiques descriptives du nombre de mots par paquet permettent d'évaluer la taille effective des unités textuelles utilisées pour l'analyse thématique. Le corpus segmenté comprend 5327 paquets, avec une moyenne d'environ 785 mots par paquet. La médiane, située à 753 mots, est relativement proche de cette moyenne, ce qui indique que la majorité des paquets se situe autour d'un volume textuel comparable.

L'écart-type est d'environ 212 mots, ce qui traduit une dispersion modérée autour de la moyenne. Le coefficient de variation est d'environ 27 %, puisqu'il correspond au rapport entre l'écart-type et la moyenne. Cette valeur indique que les paquets ne sont pas parfaitement homogènes en longueur, mais que la variabilité reste acceptable pour une analyse thématique. Cette variation s'explique par le fait que les paquets sont construits à partir d'un nombre fixe de phrases, et non d'un nombre fixe de mots : selon le style, le rythme narratif ou la longueur syntaxique des phrases, deux paquets de 40 phrases peuvent contenir un nombre de mots assez différent.

Les quartiles permettent de préciser cette distribution. Un quart des paquets contient au maximum 636 mots, tandis que la moitié des paquets contient au maximum 753 mots. Le troisième quartile, situé à 902,5 mots, indique que 75 % des paquets ne dépassent pas environ 903 mots. Ainsi, la majorité des unités d'analyse se concentre dans une zone relativement stable, comprise approximativement entre 636 et 903 mots pour la moitié centrale du corpus. Cette concentration est favorable au topic modeling, car elle limite les écarts de taille entre les unités comparées.

Les valeurs extrêmes doivent toutefois être prises en compte. Le paquet le plus court contient seulement 42 mots, tandis que le plus long atteint 2944 mots. Ces deux valeurs indiquent la présence d'unités atypiques. Le paquet de 42 mots correspond probablement à une fin de roman ou à un segment résiduel composé de moins de phrases que les autres. À l'inverse, le paquet de 2944 mots peut provenir d'un passage composé de phrases particulièrement longues ou d'une

segmentation imparfaite du texte source. Ces cas extrêmes peuvent influencer l'analyse, car un paquet très long contient davantage d'information lexicale et peut donc peser plus fortement dans la représentation des thèmes.

Dans l'ensemble, ces statistiques montrent que la segmentation en paquets de 40 phrases produit des unités textuelles globalement comparables. Malgré une variabilité réelle, la distribution reste suffisamment concentrée autour de la médiane pour permettre une analyse thématique cohérente. Il serait toutefois pertinent d'examiner les paquets extrêmes afin de vérifier s'ils correspondent à des cas normaux du corpus ou à des problèmes de segmentation.

3.4 Lemmatisation du corpus de Zola

Après avoir obtenu un corpus segmenté en paquets de phrases et relativement homogène en termes de nombre de mots, la prochaine étape de préparation des données a consisté à effectuer une lemmatisation du corpus.

Pour réaliser cette lemmatisation, nous avons utilisé la bibliothèque `spaCy` en Python, qui offre des outils performants pour le traitement automatique du langage. La lemmatisation permet de regrouper les différentes formes d'un même mot sous une seule forme de base : par exemple, les mots « manger », « mange » et « manges » sont tous réduits au lemme « manger ». Cette étape facilite l'identification des thèmes et contribue à réduire la dimensionnalité du corpus.

Comme pour la segmentation en paquets de phrases, plusieurs essais ont été réalisés avec la bibliothèque de lemmatisation `spaCy`.

```
1 nlp = spacy.load("fr_core_news_lg", disable=["ner", "parser"])
2 # Chargement du modèle de langue française de spaCy.
3 # Les composants de reconnaissance des entités nommées et d'analyse
4 # syntaxique sont désactivés afin d'accélérer le traitement.
5
6 nlp.max_length = 2_000_000
7 # Augmentation de la longueur maximale des textes traités par spaCy.
8 # Cette valeur est ajustable selon la taille des textes et la mémoire
9 # disponible sur la machine.
```

Listing 2 – Importation du modèle français de `spaCy`

Nous avons choisi d'utiliser le modèle `fr_core_news_lg` de `spaCy`, qui est un modèle de langue française de grande taille. Ce choix a été motivé par la richesse lexicale et la complexité syntaxique des romans de Zola, qui nécessitent un modèle capable de gérer une grande variété de formes linguistiques. Le modèle `fr_core_news_lg` a été retenu car il offre une lemmatisation plus précise que des modèles plus légers³, ce qui est important pour l'identification des thèmes dans les textes littéraires.

Une liste de mots à exclure a été construite progressivement au cours de plusieurs itérations de prétraitement⁴. Elle résulte de l'observation conjointe des sorties de lemmatisation et de la matrice terme-document. L'objectif était

3. Les modèles `fr_core_news_sm` et `fr_core_news_md` ont également été envisagés.

4. Elle est présente en annexe du document.

d'identifier les formes lexicales très fréquentes dans le corpus, mais peu discriminantes pour l'analyse thématique.

Cette liste contient d'abord des mots-outils, tels que les pronoms personnels, les conjonctions, les déterminants et les prépositions. Ces termes structurent grammaticalement les phrases, mais ils ne permettent pas d'identifier les thèmes dominants des romans. Leur présence importante dans la matrice terme-document risquait donc de réduire la lisibilité des topics produits par la NMF.

La liste a également été enrichie par l'ajout de certains noms propres, notamment des noms de personnages récurrents dans les romans de Zola. Ces noms apparaissent fréquemment dans les textes, mais leur poids lexical tendait à orienter les topics vers des personnages plutôt que vers des thèmes plus généraux, comme le travail, la famille, la religion, l'argent ou les rapports sociaux. Leur exclusion permet donc de privilégier une interprétation thématique plutôt qu'une simple identification des protagonistes.

Ce filtrage relève d'un choix méthodologique empirique. Lors des premiers essais, plusieurs mots restaient fortement représentés dans les résultats malgré les paramètres appliqués au lemmatiseur et au vectoriseur. La liste d'exclusion a donc été ajustée à partir de l'examen des termes les plus fréquents et des premiers topics obtenus. Elle vise à améliorer la qualité interprétative de la matrice terme-document en conservant prioritairement les mots porteurs d'information thématique.

```
1
2 def nettoyer_texte(texte):
3     """Nettoie et lemmatise un texte avec spaCy."""
4     doc = nlp(texte)
5     tokens = []
6
7     for token in doc:
8         lemme = token.lemma_.lower()
9
10        if (
11            not token.is_stop
12            and not token.is_punct
13            and not token.like_num
14            and not token.is_space
15            and token.pos_ in {"NOUN", "ADJ"}
16            and len(lemme) > 2
17            and lemme not in stop_word
18        ):
19            tokens.append(lemme)
20
21    return " ".join(tokens)
```

Listing 3 – Fonction de lemmatisation avec exclusion de mots spécifiques